Sistema para Identificação da Pinta Preta na Tangerina Ponkan, orientado por Visão Computacional

Arthur Parra, Danielli Reis, Guilherme Pereira,
Gustavo Kletelinger, Matheus Oliveira

Faculdade de Tecnologia do Estado de São Paulo

arthur.silva56@aluno.cps.sp.gov.br, danieli.reis@aluno.cps.sp.gov.br,
guilherme.pereira26@aluno.cps.sp.gov.br, matheus.oliveira52@aluno.cps.sp.gov.br,
gustavo.kletelinger@aluno.cps.sp.gov.br

Resumo

Este trabalho apresenta um sistema para a identificação precoce da Pinta Preta dos citros (Phyllosticta citricarpa) na tangerina Ponkan, voltado para o uso direto em campo. A solução integra uma aplicação móvel a um modelo de Redes Neurais Convolucionais (CNN) otimizado para Visão Computacional (VC), permitindo analisar fotos capturadas por smartphones, classificando automaticamente o estado fitossanitário dos frutos e gerando relatórios com recomendações de manejo. Para o desenvolvimento da CNN, utiliza-se um banco de imagens diversificado, coletado sob condições reais de iluminação e ruído de plantação. O sistema tem como objetivo atender a critérios rigorosos de tempo de resposta para otimizar as medidas preventivas adotadas pelo produtor rural. Espera-se que os resultados evidenciem a eficácia e a aplicabilidade da arquitetura proposta na democratização do diagnóstico agrícola e na redução de perdas produtivas.

Palavras-chave: Pinta Preta dos Citros; Visão Computacional; Redes Neurais Convolucionais

Abstract

This work presents a system for the early identification of citrus black spot in Ponkan tangerines, designed for in-field application. The solution integrates a mobile application with a CNN-based Computer Vision framework, enabling the analysis of smartphone-captured images, automatically classifying the fruit's phytosanitary status, and generating reports with management recommendations. For the development of the CNN, a diverse dataset is utilized, collected under real-world lighting conditions and field background noise. The system aims to meet strict response time requirements to optimize preventive measures adopted by rural producers. Expected results demonstrate the efficacy and applicability of the proposed architecture in democratizing agricultural diagnostics and reducing production losses.

Keywords: Citrus Black Spot; Computer Vision; CNN

1 Introdução

Os Objetivos de Desenvolvimento Sustentável (ODSs) foram adotados pela Organização das Nações Unidas [1] no ano de 2015, estabelecendo parâmetros para políticas nacionais sobre 17 temáticas que impactam o desenvolvimento humano em todos os países. Entre esses objetivos, o projeto de identificação da Pinta Preta (*Phyllosticta citricarpa*) por Visão Computacional relaciona-se profundamente com os ODSs 2, 9 e 12, que propõem medidas para garantir segurança alimentar com agricultura sustentável, fomento da inovação nos setores produtivos e eficiência no uso dos recursos naturais, respectivamente. Esses objetivos serão trabalhados com enfoque na tangerina Ponkan (*Citrus reticulata*), uma cultura de destaque na região do Vale do Ribeira.

Sendo o Brasil o maior produtor mundial de laranja e suco de laranja (USDA, 2025) [2], torna-se evidente a importância nacional deste gênero conhecido como citros (*Citrus*), composto por espécies de laranja, limão, lima, tangerina/mexerica, pomelo/toranja e cidra. Dentre elas, a tangerina possui um grande valor socioeconômico no Vale do Ribeira e uma forte presença na agricultura familiar regional. Segundo o Departamento de Economia Rural (DERAL/SEAB) [3], a citricultura permanece a principal atividade de fruticultura paranaense, ocupando 6,9 mil hectares do estado no ano de 2024. Outro levantamento realizado pela EMBRAPA [4] no mesmo ano apontou que municípios do Vale do Ribeira aparecem entre os maiores produtores, como Pariquera-Açu (SP) e Iguape (SP) com produção anual superior a 23 mil e 5,6 mil toneladas, respectivamente.

Nesse contexto, a conexão entre citricultura e agricultura familiar torna-se um pilar fundamental no desenvolvimento da região, considerando que "mais de 60% dos estabelecimentos agrícolas do Vale do Ribeira são compostos por pequenos agricultores familiares"(tradução nossa) (PAGASSINI et al., 2024) [5]. Para esse grupo social, a tangerina Ponkan atende a diversas necessidades, uma vez que se adaptou bem às condições edafoclimáticas locais. A drenagem do solo incentiva o crescimento de raízes profundas para melhor captação de água; enquanto o clima subtropical úmido, com alta umidade relativa do ar e temperaturas moderadas a altas, favorece a suculência e o tamanho dos frutos (BORGES et al., 2020) [6].

Essas características apreciadas pelo consumidor definem a tangerina como um produto de comercialização principalmente *in natura*, sustentando não apenas o mercado externo, mas toda uma cadeia de pequenas propriedades que são afetadas diretamente pelos problemas da cultura. Por exemplo, a sazonalidade do mercado, em razão da safra concentrada entre os meses de abril e julho, pode afetar diretamente famílias que têm o cultivo de Ponkan como fonte de renda principal. Outro fator decisivo é a produtividade, muitas vezes prejudicada por questões fitossanitárias, ou seja, pragas e doenças.

O cenário nacional de citros enfrenta grandes ameaças de agentes nocivos como insetos, bactérias e fungos. Uma das doenças mais importantes é a Pinta Preta ou mancha preta dos citros, a qual, segundo Silva Junior et al. (2016, p. 14) [7], foi relatada em 1980 no estado do Rio de Janeiro e encontra-se praticamente em todas as regiões citrícolas do país. Trata-se de uma doença fúngica causada pelas formas reprodutivas assexuada *Phyllostictina citricarpa* e sexuada *Guignardia citricarpa*, caracterizada pela queda prematura dos frutos, cujas cascas são acometidas por lesões que também desqualificam significativamente o produto para comercialização. Ademais, lesões de Pinta Preta são dotadas de certa variabilidade e podem se assemelhar a danos mecânicos ou insetos, confundindo o produtor. Os principais sintomas são manchas dura, sardenta, virulenta, rendilhada, trincada e a falsa melanose, com manifestação favorecida pela exposição ao sol em altas temperaturas. Portanto, “o manejo da doença em pomares para o mercado interno deve ser muito rigoroso e eficiente” (SILVA JUNIOR et al., 2016) [7].

Para o enfrentamento de desafios fitossanitários como esse, o conceito de agricultura de precisão (AP) tem se destacado como uma abordagem inteligente da prática agrícola. Segundo Molin, Amaral e Colaço (2015) [8], a AP esteve fortemente vinculada ao georreferenciamento

no seu início, e mais recentemente pode ser entendida como a aplicação da tecnologia da informação (TI) em campo. Sua finalidade de reduzir custos e aumentar produtividade baseia-se na compreensão de que as propriedades agrícolas não são uniformes espacialmente ou ao longo do tempo, o que exige o desenvolvimento de estratégias para gerenciar a heterogeneidade das lavouras e seus respectivos problemas.

Nesse cenário, a VC “pode ser empregada na detecção de doenças e pragas, na estimação de safra e na avaliação não invasiva de atributos como qualidade, aparência e volume, sendo alimentada por imagens capturadas por equipes de campo e dispositivos móveis, como smartphones, ou por câmeras acopladas a tratores, robôs e VANTs"(SANTOS et al., 2020) [9], "além de ser componente essencial em sistemas robóticos agrícolas”. O mesmo estudo aborda a classificação de padrões associados a objetos de interesse e sintomas de doenças e pragas como problemas perceptuais abordados pela VC.

Apesar de existirem na literatura estudos que abordam a inteligência artificial voltada à citricultura (MOMENY et al., 2022; MARQUES et al., 2022) [10] [11], tais abordagens concentram-segurança em uma validação isolada de Redes Neurais Convolucionais em condições controladas de laboratório ou em grandes monoculturas. Todavia, mantém-se uma lacuna no desenvolvimento de arquiteturas integradas que aliem a detecção por imagem ao contexto operacional e socioeconômico do produtor familiar/pequeno produtor rural (PAGASSINI et al., 2024) [5].

Para preencher essa lacuna, este trabalho apresenta o sistema Vita, focado no diagnóstico e manejo preventivo da Pinta Preta em pomares de tangerina Ponkan. A arquitetura utiliza métodos de Processamento Digital de Imagens (PDI) (GONZALEZ; WOODS, 2010) [12] como etapa de pré-processamento para padronizar atributos de cor (sRGB), dimensões operacionais (224x224 pixels) e remoção de ruídos em fotos obtidas por smartphones no campo. Essas matrizes tratadas alimentam o pipeline de inferência composto pelas redes YOLO (REDMON et al., 2016) e EfficientNet (M. Tan e Q. V. Le, 2019) [13], integrando os resultados a alertas climáticos locais e orientações práticas em uma interface acessível para o produtor familiar do Vale do Ribeira.

2 Objetivo

Desenvolver um sistema capaz de identificar sintomas da Pinta Preta na tangerina Ponkan, capturados em foto via câmera de telefone celular, utilizando métodos de Inteligência Artificial e Visão Computacional de modo a otimizar as medidas preventivas em campo.

Em paralelo, o projeto possui objetivos secundários que complementam sua finalidade principal:

- Alcançar acurácia mínima de 80% na identificação da Pinta Preta em fotos de tangerinas através de CNN;
- Garantir, desde o envio de imagens para análise até a exibição dos resultados, um tempo de processamento máximo de 10 segundos;
- Desenvolver um algoritmo para recomendação de práticas de manejo com prazos, baseado em análise de dados climáticos;
- Desenvolver um mapeamento gráfico dos pontos de infecção analisados e suas respectivas áreas de risco no pomar, baseado no georreferenciamento de dispositivos móveis.

3 Estado da Arte

A detecção automatizada de doenças na agricultura tornou-se essencial para reduzir perdas produtivas e substituir a subjetividade da inspeção visual humana. Para atender a essa demanda,

a literatura recente abandonou o processamento manual de imagens em favor das redes neurais convolucionais. Esse avanço reflete a necessidade atual do setor: criar sistemas de VC rápidos, capazes de operar sob as interferências de um ambiente real de plantação e acessíveis diretamente por smartphones.

Historicamente, as abordagens iniciais para o diagnóstico fitossanitário apoiaram-se em Redes Neurais Artificiais (RNAs) clássicas combinadas à extração manual de características. Um exemplo dessa abordagem é o trabalho de Ribeiro, Castro Jorge e Paiva (2012) [14], cujo objetivo foi diferenciar o greening de outras doenças foliares e deficiências nutricionais em citros, como alternativa ao alto custo da PCR. Utilizando 60 folhas digitalizadas em scanner, os autores empregaram uma RNA treinada com 46 imagens para segmentação de cores em máscaras binárias, combinada a descritores matemáticos de forma para medir a assimetria das lesões. O estudo concluiu que a segmentação de cor isolada atingiu 96,04% de precisão, mas a classificação geral variou entre 43% e 63%, evidenciando a necessidade de associar cor e forma, além de apontar as limitações dos métodos manuais baseados em scanners.

Superando as limitações da extração manual das RNAs clássicas, Marques, Pontelli e Paiva (2022) [11] consolidaram o emprego de CNNs na identificação do greening em plantações de citros. A metodologia baseou-se na técnica de aprendizado por transferência utilizando a arquitetura InceptionV3, implementada em Python com as bibliotecas Keras, TensorFlow, Numpy e scikit-learn, utilizando imagens de câmeras digitais divididas entre fundos homogêneos e reais. Para mitigar ruídos visuais de campo (como solo e galhos), aplicou-se a técnica de data augmentation (translação, rotação e brilho). Os resultados demonstraram que o ajuste de todos os pesos neurais atingiu 99,33% de acurácia em estúdio e manteve robustos 95,99% em ambiente real, provando a superioridade das CNNs para contornar ruídos visuais em condições abertas.

Em uma abordagem ainda mais próxima dos objetivos deste projeto, Momeny et al. (2022) [10] empregaram CNNs associadas à estratégia de learning-to-augment para a detecção da Pinta Preta (black spot) em laranjas. O dataset integrou 1.896 imagens capturadas por um smartphone (Samsung SM-J500H, resolução de 4128 x 2322 pixels), avaliando múltiplos modelos de deep learning (MobileNetV2, GoogleNet, DenseNet201 e ResNet50) processados via MATLAB. O modelo ResNet50 sobressaiu-se com 99,5% de acurácia total, 100% de sensibilidade e especificidade. O estudo validou com sucesso a viabilidade de sistemas rápidos e de baixo custo baseados em câmeras de smartphones para o manejo fitossanitário.

Em síntese, enquanto os trabalhos de Ribeiro, Castro Jorge e Paiva (2012) [14], Marques, Pontelli e Paiva (2022) [11] e Momeny et al. (2022) [10] mapeiam a transição tecnológica dos métodos manuais clássicos para a robustez das CNNs em ambientes abertos e em dispositivos móveis, a literatura examinada fornece o embasamento metodológico essencial. Considerando que as CNNs especializam-se nativamente no tratamento de dados com estrutura espacial, os achados sustentam diretamente a arquitetura de VC proposta para o projeto.

4 Metodologia

Esta pesquisa caracteriza-se como um estudo de natureza aplicada com abordagem experimental, voltado ao desenvolvimento de um sistema multiplataforma de pré-diagnóstico fitossanitário para a identificação precoce da Pinta Preta (Phyllosticta citricarpa) na cultura da tangerina Ponkan, visando a otimização de medidas preventivas no Vale do Ribeira.

O sistema será estruturado em uma arquitetura de microsserviços para garantir escalabilidade e independência entre os módulos. A orquestração da Interface de Programação de Aplicações (API) será realizada em Node.js (OPENJS FOUNDATION, 2026) [15], enquanto o módulo de Inteligência Artificial (IA) utilizará a linguagem Python (PYTHON SOFTWARE FOUNDATION, 2026) [16]. A persistência de dados será gerenciada pelo banco PostgreSQL () [] via Object-Relational Mapping (ORM) Sequelize, com suporte do Redis (REDIS LTD, 2026) [17] e da biblioteca BullMQ para o gerenciamento de filas assíncronas. A comunicação entre os mó-

dulos ocorrerá via API com estilo arquitetural Representational State Transfer (REST). Para assegurar a responsividade da interface multiplataforma (React Native, META, 2026; Next.js, VERCEL, 2026) [18] [19], o processamento será delegado a workers assíncronos. O pipeline de tratamento utilizará a biblioteca Sharp (LOVELL, 2026) [20] para redimensionamento (224x224 px), filtragem de ruído, ajustes de contraste, conversão para padrão sRGB e extração de buffer binário.

A inferência será realizada por uma arquitetura de CNN em duas fases: o algoritmo YOLO (REDMON et al., 2016) [21] detectará as lesões, enquanto a rede EfficientNet (TAN; LE, 2019) [13] realizará a classificação das patologias com um limiar de confiança de 80%. O sistema operará através dos módulos de Diagnóstico, Contexto, Recomendação - fundamentado nos protocolos de manejo da Embrapa (BORGES et al., 2020) [6] e Fundecitrus (SILVA JUNIOR et al., 2016) [7] - e Diagramação, utilizando a estratégia de "deleção lógica"para assegurar a rastreabilidade dos registros.

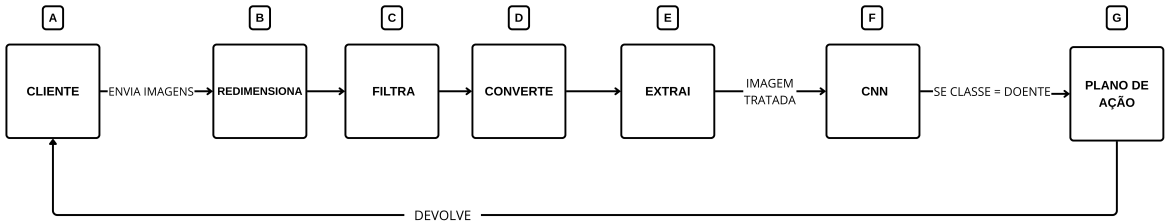


Figura 1: Fluxo de processamento de imagens do sistema.
Fonte: Autoria própria.

Referências

[1] Nações Unidas. (2025) Objetivos de desenvolvimento sustentável (ods). [Online]. Available: https://brasil.un.org/pt-br/sdgs

[2] USDA. (2025) Citrus: World markets and trade. [Online]. Available: https://apps.fas.usda.gov/psdonline/circulars/citrus.pdf

[3] Departamento de Economia Rural (DERAL), "Boletim semanal deral nº 14/2024," Secretaria da Agricultura e do Abastecimento do Paraná (SEAB), Curitiba, Tech. Rep., 2024. [Online]. Available: https://www.agricultura.pr.gov.br/sites/default/arquivos_restritos/files/documento/2024-04/boletim_semanal_14_deral_04_abr_24.pdf

[4] Empresa Brasileira de Pesquisa Agropecuária (EMBRAPA), "Produção brasileira de tangerina por município," EMBRAPA Mandioca e Fruticultura, Cruz das Almas, Tech. Rep., 2024. [Online]. Available: https://www.cnpmf.embrapa.br/Base_de_Dados/index_pdf/dados/brasil/tangerina/b32_tangerina.pdf

[5] J. A. V. Pagassini, L. C. F. d. Almeida, and M. C. d. G. Gasparoto, "Perception and adoption of integrated plant disease management by family farmers in ribeira valley (são paulo state, brazil)," *Revista Caderno Pedagógico*, vol. 21, no. 3, pp. 1–22, 2024.

[6] A. L. Borges, E. A. Girardi, and L. d. S. Souza, "Recomendação de calagem e adubação," in *Calagem e adubação para os citros (laranjeiras, limeiras-ácidas e tangerineiras)*. EMBRAPA, 2020. [Online].

Available: https://www.infoteca.cnptia.embrapa.br/infoteca/bitstream/doc/1134672/1/cap9-livro-RecomendacaoCalagemAdubacao-AnaLuciaBorges-AINFO-1.pdf

[7] G. J. Silva-Junior, E. Feichtenberger, M. B. Spósito, L. Amorim, R. B. Bassanezi, and A. d. Goes, *Pinta preta dos citros: a doença e seu manejo*, 1st ed. Araraquara: Fundecitrus, 2016. [Online]. Available: https://www.fundecitrus.com.br/wp-content/uploads/2025/07/Livro-Pinta-Preta.pdf

[8] J. P. Molin, L. R. d. Amaral, and A. Colaço, *Agricultura de Precisão*. Oficina de Textos, 2015. [Online]. Available: https://play.google.com/store/books/details?id=MX7jCgAAQBAJ

[9] T. T. Santos, J. G. A. Barbedo, S. Ternes, J. Camargo Neto, L. V. Koenigkan, and K. X. S. d. Souza, "Visão computacional aplicada na agricultura," in *Agricultura Digital: Pesquisa, Desenvolvimento e Inovação nas Cadeias Produtivas*, S. M. Fonseca, S. Massruhá, and outros, Eds. Brasília, DF: Embrapa, 2020, pp. 146–164, capítulo 6. [Online]. Available: https://www.alice.cnptia.embrapa.br/alice/bitstream/doc/1126261/1/LV-Agricultura-digital-2020-cap6.pdf

[10] M. Momeny *et al.*, "Detection of citrus black spot disease and ripeness level in orange fruit using learning-to-augment incorporated deep networks," *Ecological Informatics*, vol. 71, p. 101829, 2022. [Online]. Available: https://www.sciencedirect.com/science/article/abs/pii/S1574954122002795

[11] M. N. Marques, C. O. Pontelli, and E. C. de Paiva, "Identificação de huanglongbing (hlb) em plantações de citros utilizando redes convolucionais profundas," *Congresso Brasileiro de Automática (CBA)*, 2022. [Online]. Available: https://sba.org.br/open_journal_systems/index.php/cba/article/view/3507/3036

[12] R. C. Gonzalez and R. E. Woods, "Digital image processing," *Pearson Prentice Hall*, 2010.

[13] M. Tan and Q. V. Le, "Efficientnet: Rethinking model scaling for convolutional neural networks," *Proceedings of the International Conference on Machine Learning (ICML)*, 2019.

[14] P. P. E. Ribeiro, L. A. Castro Jorge, and M. S. V. Paiva, "Diferenciação do greening de outras doenças foliares em citros utilizando técnicas de processamento de imagens," 2012. [Online]. Available: https://swfrec.ifas.ufl.edu/hlb/database/pdf/00002955.pdf

[15] OpenJS Foundation. (2026) Node.js documentation. [Online]. Available: https://nodejs.org/

[16] Python Software Foundation. (2026) Python language reference, version 3.x. [Online]. Available: https://www.python.org/

[17] Redis Ltd. (2026) Redis documentation. [Online]. Available: https://redis.io/docs/

[18] Meta. (2026) React Native: Learn once, write anywhere. [Online]. Available: https://reactnative.dev/

[19] Vercel. (2026) Next.js documentation. [Online]. Available: https://nextjs.org/docs

[20] L. Fuller. (2026) sharp: High performance Node.js image processing. [Online]. Available: https://sharp.pixelplumbing.com/

[21] J. R. et al., "You only look once: Unified, real-time object detection," *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2016.